BENCHMARK DES MODÈLES LLM OLLAMA

Plateforme de commande intelligente Givaudan — Arômes & parfums pour petites entreprises

Contexte. Givaudan travaille en B2B avec des entreprises globales, régionales et locales, dont de petites entreprises. Le projet vise à imaginer une plateforme capable de comprendre le besoin d'une petite entreprise, de l'orienter vers la bonne solution et de simplifier sa commande grâce à l'IA. Givaudan propose notamment un catalogue de fragrances, des filtres de recherche, des échantillons et des possibilités de commande ; son offre mentionne un MOQ de 5 kg pour le catalogue et 25 kg pour une création personnalisée. ■cite■turn466034search24■turn466034search7■

1. Objectif du benchmark

Déterminer quel modèle local Ollama est le plus adapté pour jouer le rôle d'un assistant commercial destiné aux petites entreprises : comprendre une demande parfois imprécise, poser les bonnes questions, reformuler le besoin, recommander une solution sans inventer de référence et préparer les informations nécessaires à une commande.

2. Modèles sélectionnés

Modèle Ollama	Pourquoi le tester
llama3.2:3b	Petit modèle, dialogue multilingue, fonctionnement local léger.
mistral:7b	Modèle généraliste français, intéressant pour la conversation B2B.
qwen2.5:7b	Multilingue, bon suivi d'instructions et raisonnement général.
gemma3:4b	Modèle compact avec de bonnes capacités de compréhension et de dialogue.
phi3.5:3.8b	Modèle léger à comparer pour la rapidité et l'efficacité locale.

Les modèles et tailles proposés correspondent à des modèles disponibles dans la bibliothèque Ollama ; les tailles peuvent être adaptées selon les ressources du Mac. ■cite■turn466034search0■turn466034search2■turn466034search5■turn466034search9■

3. Scénarios de test — petites entreprises

ID	Situation	Prompt identique pour chaque modèle
T1	Besoin imprécis	Je dirige une petite entreprise qui fabrique des boissons artisanales. Je cherche un arôme fruité, mais je ne sais p
T2	Choix d'un arôme	Notre petite entreprise cherche un arôme naturel de fraise pour une boisson. Quels critères faut-il vérifier avant de
T3	Petite quantité	Nous voulons tester une nouvelle recette et nous avons besoin d'une petite quantité d'arôme citron. Quelles inform
T4	Budget limité	Nous sommes une petite entreprise avec un budget limité. Nous cherchons un profil vanille-caramel. Comment no
T5	Reformulation commerciale	Reformule ce besoin pour un commercial : « Je veux quelque chose de frais, citronné, pas trop fort, pour une bois
T6	Conseil responsable	Je veux commander un arôme pour un produit alimentaire. Quelles informations réglementaires ou techniques de
T7	Cas parfum	Je suis une petite marque de cosmétiques et je cherche une fragrance fraîche et propre pour un nouveau produit.

4. Critères de notation

Critère	Question à se poser	Poids
Compréhension du besoin	Le modèle comprend-il le besoin même s'il est exprimé simplement ?	20 %
Questions de clarification	Pose-t-il les questions réellement utiles avant de recommander ?	15 %
Pertinence	Sa réponse correspond-elle au produit, à l'application et aux contraintes ?	20 %
Adaptation aux petites entreprises	Prend-il en compte petites quantités, budget, simplicité et accompagnement ?	15 %
Qualité du français	La réponse est-elle claire, naturelle et professionnelle ?	10 %
Fiabilité / prudence	Évite-t-il d'inventer des références, prix ou caractéristiques ?	10 %
Rapidité	Le modèle répond-il rapidement sur le Mac ?	10 %

5. Échelle de notation

1 = très mauvais **2** = insuffisant **3** = moyen **4** = bon **5** = excellent.
Pour chaque scénario, noter chaque critère. Le score final peut être calculé avec les poids ci-dessus.

6. Tableau de résultats

Modèle	Compr.	Questions	Pertin.	PME	Français	Fiabilité	Rapidité	Score /5
llama3.2:3b								
mistral:7b								
qwen2.5:7b								
gemma3:4b								
phi3.5:3.8b								

7. Mesures techniques à relever dans Ollama

Mesure	À relever
Temps de réponse	Temps nécessaire pour obtenir la réponse.
Taille du modèle	Taille téléchargée/occupée sur le Mac.
Qualité	Score moyen obtenu avec les scénarios.
Facilité d'utilisation	Commande Ollama et stabilité du modèle.

8. Conclusion attendue

Après les tests, le modèle retenu devra être celui qui offre le meilleur compromis entre qualité des réponses, compréhension des besoins des petites entreprises, pertinence des recommandations, fiabilité, rapidité et consommation de ressources. La conclusion devra expliquer le choix à partir des résultats observés et non d'une préférence théorique.

À retenir : le benchmark ne cherche pas à savoir quel LLM est « le meilleur » en général. Il cherche à savoir quel modèle est le plus utile pour **la mission Givaudan** : accompagner une petite entreprise vers le bon arôme ou parfum et faciliter sa commande.